

# SVM-KKT

SVM을 최적화 하기 위해선 KKT 조건을 활용한다.

SVM의 제약조건은 릿지회귀에서 보다 더 복잡하므로 KKT 조건을 사용하여 최적화를 진행한다.

$$\text{목적함수} \quad \min \frac{1}{2} \|w\|^2$$

$$\text{제약조건} \quad y_i(w^T x_i + b) \geq 1$$

라그랑주 함수 정의

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i \{ y_i (w^T x_i + b) - 1 \}$$

KKT 조건

① stationarity

$$\nabla L(w, b, \alpha) = 0$$

② primal feasibility

$$y_i (w^T x_i + b) \geq 1$$

③ dual feasibility

$$\alpha_i \geq 0$$

④ complementary slackness

$$\alpha_i \{ y_i (w^T x_i + b) - 1 \} = 0$$

stationarity

$\nabla L(w, b, \alpha)$ 를 계산해보겠다.

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i \{y_i (w^T x_i + b) - 1\}$$

$$\frac{d}{dw} L(w, b, \alpha) = w - \sum_{i=1}^n \alpha_i y_i x_i = 0$$

$$w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\frac{d}{db} L(w, b, \alpha) = - \sum_{i=1}^n \alpha_i y_i = 0$$

$$\sum_{i=1}^n \alpha_i y_i = 0$$

종합하자면, 다음 2가지 결과를 얻었다

$$w^* = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\sum_{i=1}^n \alpha_i y_i = 0$$

라그랑주 함수를 duality를 이용하여 푸는 이유는 다음과 같다.

라그랑주 함수의 개형을 보면 아래와 같은데

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i y_i (w^T x_i + b) - 1$$

$w$ 와  $b$ 에 대해서 라그랑주 함수는 convex하다. 함수가 convex하다는 것은 최적화 문제에서 큰 이점을 갖는데, 그 이유는 Convex 함수의 경우, local minimum이 곧 global

minimum이 되며, convex 함수의 stationary point(그라디언트가 0이 되는 지점)에서 최적화를 제공하는 강력한 이점이 있다.

하지만, 또 다른 변수인 승수  $\alpha$ 에 대해선 convex하지 않다. 즉, 목적함수를 최소화 하려면  $w$ 와  $b$ 를 최소화 해야 하지만  $\alpha$ 는 최대화 하는 문제가 있다.

따라서 duality를 이용하여 라그랑주 함수를  $\alpha$ 에 대한 식으로만 나타내어서  $\alpha$ 를 최대화 하여 최적화를 이루어 낸다.

dual problem의 변환은 다음과 같은 이점을 제공한다.

1. 계산 효율성

듀얼 문제는 종종 원 문제보다 더 적은 수의 변수로 표현될 수 있다. 특히, SVM에서는 훈련 데이터의 수가 특성의 수보다 많을 때 이 이점이 두드러진다.

2. kernel trick 사용

듀얼 문제 형태를 사용하면, kernel trick을 적용하여 고차원 공간에서의 선형 분리를 용이하게 할 수 있다. 이는 비선형 분류 문제를 해결하는 데 효과적이다.

3. sparse 해

듀얼 문제의 해는 대부분의

$\alpha$ 가 0이 되는 sparse해(희소 해)를 제공한다. 이는 결정 경계를 정의하는 데 단지 소수의 서포트 벡터만이 필요하다는 것을 의미한다. 이로 인해 모델의 일반화 능력이 향상되고, 계산 비용도 절감된다.

$L(w, b, \alpha)$ 를  $w^* = \sum_{i=1}^n \alpha_i y_i x_i$ 를 이용하여

dual 문제  $L(w^*, b^*, \alpha)$ 의 해를 찾아 보겠다.

$$\frac{1}{2} \|w^*\|^2 = \frac{1}{2} w^{*T} w^*$$

$$= \frac{1}{2} w^{*T} \sum_{i=1}^n \alpha_i y_i x_i$$

$$= \frac{1}{2} \sum_{i=1}^n \alpha_i y_i (w^{*T} x_i)$$

$$w^{*T} = \sum_{j=1}^n \alpha_j y_j x_j^T$$

$$= \frac{1}{2} \sum_{i=1}^n \alpha_i y_i \sum_{j=1}^n \alpha_j y_j x_j^T x_i$$

$$= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_j^T x_i$$

$$\begin{aligned}
& \sum_{i=1}^n \alpha_i \left\{ y_i (w^T x_i + b) - 1 \right\} \\
&= \sum_{i=1}^n \alpha_i y_i (w^T x_i + b) - \sum_{i=1}^n \alpha_i \\
&= \sum_{i=1}^n \alpha_i y_i w^T x_i + b \sum_{i=1}^n \alpha_i y_i - \sum_{i=1}^n \alpha_i \\
&\quad \sum_{i=1}^n \alpha_i y_i = 0 \\
&\quad \sum_{i=1}^n \alpha_i y_i w^T x_i = \|w^*\|^2 \\
&= \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_j^T x_i - \sum_{i=1}^n \alpha_i
\end{aligned}$$

이를 통해서  $L(w^*, b^*, \alpha) = \sum_{i=1}^n \alpha_i - \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$

원래 라그랑주 함수는  $L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i \{y_i (w^T x_i + b) - 1\}$

목적함수인  $\frac{1}{2} \|w\|^2$ 를 최소화하려면  $\alpha$ 를 최대화 해야 한다.

$L(w^*, b^*, \alpha)$ 를  $L_{dual}(\alpha)$ 라 둔다면  $\alpha$ 를 최대화 해야 한다.

정리해라면,

$$\text{maximize } L_{dual}(\alpha) = \sum_{i=1}^n \alpha_i - \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$\text{subject to } \begin{cases} \sum_{i=1}^n \alpha_i y_i = 0 \\ \alpha_i \geq 0 \end{cases}$$